LABORATUVAR 7 · PAKETPRO 3000 · MİR250 AMR

AI Safety Challenge

Çıktı: AI Fail-Safe Decision

Ad Soyad Betül Altunyuva 235542020 | Grup Gece-B | Tarih 06.11.2026

Kavram — Prediction ≠ Safety: Yapay zekâ bir karar üretir; güvenliği garanti eden mimari YZ'nin **dışında** tanımlanmalıdır. Araçlar: fail-safe · human override · monitoring · confidence threshold · fallback.

Varsayım

MiR250'nin okunan üretici belgelerinde YZ modeli yer almıyor; 3D kameralar navigasyon içindir. Bu föy için kameraya **YZ tabanlı insan/engel sınıflandırmasının eklendiği** varsayılır. Emniyet fonksiyonu yine **SICK lazer tarayıcı + emniyet kontrolcüsü** zincirindedir.

3D kamera → YZ modeli → OK / RED (engel) → Hız önerisi → Robot hızı

Senaryo: MiR250'ye YZ'li kamera ile insan/engel sınıflandırması eklenmesi planlanıyor — proje aşaması değerlendirmesi yapıyorsunuz.

Görev — üç başarısızlıkta güvenli davranış

1. **Model yanlış sınıflandırdı:** İnsana "engel yok" dedi. Sistem ne yapmalı? İkinci kontrol / insan onayı var mı?

   YZ'nin kararı emniyet fonksiyonu sayılmaz: **lazer tarayıcı ve emniyet kontrolcüsü** bağımsız olarak koruma alanında insanı görüp robotu durdurur. YZ yalnızca hız *önerir*; emniyet hız sınırını aşamaz. Yeni rota/bölge gibi kritik kararlar için operatör onayı istenir.

2. **Girdi manipüle edildi:** Kamera verisi bozuk/sahte. Nasıl fark edilir? Şüpheli girdide ne yapılır?

   Görüntü kalitesi (bulanıklık, parlama, kapanma) ve 3D derinlik verisi izlenir; kamera ile lazer tarayıcı sonuçları **çapraz doğrulanır**. Çelişki varsa YZ çıktısı reddedilir, robot **güvenli varsayıma** (düşük hız ya da duruş) geçer, operatör uyarılır, olay kaydedilir.

3. **Confidence düştü:** Model "emin değilim" diyor. Eşik ne olmalı? Altında: dur / insana sor / fallback?

   Önerilen eşik: güven puanı 0,80'in altı (test ile doğrulanmalı). Altında: robot **yavaşlar**; durum birkaç saniye sürerse **durur ve operatöre sorar**; **fallback:** YZ'siz, lazer tabanlı navigasyon ve düşük hız.

Karar tablosu — AI Fail-Safe Decision

Başarısızlık	Tanımladığınız güvenli davranış (hangi kavramla?)
Model yanlış sınıflandırdı	Emniyet YZ'nin dışında: lazer tarayıcı + emniyet kontrolcüsü durdurur; kritik kararlarda onay. **(human override · bağımsız emniyet katmanı)**
Girdi manipüle edildi	Kamera–lazer çapraz doğrulama; şüpheli girdi reddedilir, robot güvenli varsayıma geçer. **(monitoring · fail-safe)**
Confidence düştü	Eşik altında yavaşla → dur → operatöre sor; YZ'siz navigasyona dön. **(confidence threshold · fallback)**

Bu föyün çıktısı **AI Fail-Safe Decision** → Evidence Pack **EP 03 + EP 15** başlığına oturur.